吴忠衡

求职意向：AI 应用开发 / Agent / AI 后端工程师 ｜ 2027 届本科

+86 13418131963 | 2579561724@qq.com | github.com/maxwu2579 | 个人主页 wu-zhongheng-portfolio.vercel.app

个人优势

- **LLM 应用落地**：熟悉 RAG 检索、重排与离线评测，使用 Langfuse 做全链路可观测；能设计 Human-in-the-loop 的 Agent 任务执行流程。
- **独立全流程交付**：实习公司唯一技术人员，独立负责 AI 应用、软件开发与运维，覆盖现场需求调研、架构设计、开发测试到部署发布。
- **工程质量意识**：重视幂等、事务一致性、失败恢复与降级，项目均配套完整自动化测试与技术文档。

教育背景

泰莱大学（Taylor's University） ｜ 信息科技学士（Bachelor of Information Technology） 预计 2027.04 毕业

马来西亚 · 雪兰莪 ｜ 全英文授课

实习经历

Auraplex Sdn. Bhd. ｜ AI / 软件开发实习生 2026.09 – 至今

马来西亚 · 雪兰莪 ｜ 公司唯一技术人员，独立负责 AI 应用、软件开发与运维

Smart Track V2 — 工业 OCR 条码追溯系统重构（C# / .NET 10 WinForms · Python FastAPI · PostgreSQL）

- **从零重建遗留系统**：公司 4–5 年前的旧系统已无法运行，独立研读旧源码、梳理业务规则，重新设计为 WinForms 客户端 + FastAPI 后端 + PostgreSQL 的分层架构，实现工厂 / 产品 / 批次管理、**版本化条码规则**，以及 PASS、低分、计数不足、重复、未读取等扫描判定。
- **现场调研与设备接入**：赴产线实地了解 SICK 智能相机与三菱 PLC 的通信方式、端口与信号，据此开发**相机 TCP 适配器**与 **PLC（MX Component）剔除驱动**；默认 Fake 模式，需显式审批开关才连接真实设备，避免误写产线。
- 设计**全局条码唯一性与事件幂等**机制（source_event_id + SHA-256 内容指纹，同一事务写入，提交结果未知时回查），剔除请求只派发一次，杜绝重复剔除与误判重复。
- 实现扫描历史多条件查询与 Excel 导出（上限 10 万行、防公式注入）；以 FakeCamera / FakePLC 完成断线重连与端到端验收并发布内部 Demo，pytest + xUnit 共 1,000+ 项测试用例。

企业 AI 知识库与公司官网（Next.js 16 · Keycloak · MinIO · Qdrant · Docker · Nomad · APISIX）

- 为公司 AI Server / RAG 做技术选型，离线对比多种 Embedding、Reranker 与本地推理方案的检索质量、延迟、内存与部署资源；开发**知识库上传后台**：Keycloak OIDC 按用户组授权，文件流式写入 MinIO 并展示 Qdrant 处理状态，含 CSRF 防护、限流与操作审计。
- 独立开发中 / 英 / 马来**三语公司官网**（Next.js 16 + Sanity CMS），集成 Claude 驱动的 AI 选型助手 Machine Finder（流式输出）；Docker 构建、**HashiCorp Nomad 自托管**，经 APISIX 网关与 Cloudflare Tunnel 对外发布。

内部业务工具（Python · Excel · SQLite · PyInstaller · FastAPI · Konva）

- **Material Stock Checker**：按 BOM 与计划数量计算物料需求，识别缺料及 **8 类数据异常**，结果绑定源文件版本、变更自动重算，导出 Excel 报告；PyInstaller 发布 **v1.0.0 免安装版**，开发版扩展库存快照、预警与 DeepSeek 只读库存问答助手。
- **商品图生成工具**：FastAPI + rembg 本地抠图、连通域识别主体并自动排版，Konva 画布编辑后导出标准商品图；提供一键启动脚本，供非技术同事日常使用。

GitHub：github.com/maxwu2579/Auraplex_Material_Stock_Checker

项目经历

AI Knowledge Server / MAX ｜ 多语言 RAG 文档问答系统 2026 – 至今

Python · FastAPI · Next.js · TypeScript · ChromaDB · Cross-Encoder · Langfuse · ONNX · Docker

- 实现 PDF / TXT / Markdown 解析与段落感知切分，本地 Embedding + ChromaDB 向量检索 + **Cross-Encoder 重排**，生成带文件名与页码引用的可追溯回答；中文 / 混合问题自动改写检索，证据不足时拒答。
- 接入 **Langfuse** 追踪 Query Rewrite → Retrieval → Rerank → Answer Generation 全链路，定位本地模型冷启动瓶颈并实现启动预热；重排失败降级为纯向量检索，LLM 异常可恢复。
- 构建 25 题验收集，对多种 Reranker 与 **ONNX INT8** 推理方案做离线 Benchmark（Evidence Recall@5、排序质量、P50 / P95 延迟、内存），最佳配置达 **21/21 Evidence Recall@5**；后端 183 项测试通过。

GitHub：github.com/maxwu2579/ai-knowledge-server

JARVIS ｜ Agentic AI 个人助理 2026 – 至今

Python · FastAPI · React · TypeScript · SQLAlchemy · Alembic · SQLite / PostgreSQL · pgvector · Microsoft Graph

- 设计 **LLM Gateway**（OpenAI / DeepSeek / Fake Provider 统一抽象）：自然语言经 Structured Output + Pydantic 二次校验生成任务草稿，用户确认后才执行；工具白名单 + 拒绝审计，防御 Prompt Injection。
- 构建数据库驱动的**持久化任务执行引擎**：Worker 以条件更新 + 租约原子领取任务，有上限重试、租约过期恢复，唯一约束实现 at-least-once + 去重，避免重复执行。
- 实现 **Grounded RAG**：FTS5 / BM25 与向量检索经 RRF 融合，后端分配不可伪造的引用标签并校验，证据不足明确拒答；支持 SQLite 与 PostgreSQL + pgvector 双方言。
- 接入 Microsoft Graph（OAuth）读取 Outlook 日历，经预览确认后创建事件；全量回归 600+ 项测试通过。

GitHub：github.com/maxwu2579/jarvis-personal-assistant

AI 代码差异审查服务 2026

Python · FastAPI · asyncio · SSE · DeepSeek API · Cloudflare Tunnel

- 异步服务接收 unified diff，按文件边界分块后台扫描，支持轮询与 **SSE** 流式返回结构化审查结果，经 Cloudflare Tunnel 提供公网访问。
- 实现幂等键、内容缓存、限流与信号量并发控制；本地规则引擎与 LLM 共用统一 Provider 接口，模型不可用时服务稳定降级。

GitHub：github.com/maxwu2579/diff-review-service

专业技能

编程语言： Python（熟练）· TypeScript / JavaScript · C# / .NET · SQL · Java · C++

AI / LLM： RAG · Embedding · Hybrid Search（BM25 + RRF）· Reranking · Agent · Tool Calling · Structured Output · Langfuse · ONNX

后端与前端： FastAPI · Flask · asyncio · SSE · REST API · SQLAlchemy · Alembic · React · Next.js · Vue 3 · WinForms

数据与运维： PostgreSQL · pgvector · SQLite · ChromaDB · Qdrant · MinIO · Docker · Nomad · APISIX · Keycloak · Git

AI 辅助开发： 熟练使用 Claude Code 等 AI 编程工具进行开发、测试与代码审查

证书与语言： AWS Certified Cloud Practitioner（2024）· 中文（母语）· 英语（流利）