吴忠衡

AI 应用研发 / Agent / AI Backend｜2027 届

+86 13418131963 ｜ 2579561724@qq.com ｜ github.com/maxwu2579

教育背景

泰莱大学（Taylor's University）｜信息科技学士 预计 2027.04 毕业

马来西亚 · 梳邦再也

实习经历

Auraplex Sdn. Bhd.｜AI / 软件开发实习生 2026.09 - 至今

Selangor, Malaysia

- 围绕公司 AI Server / RAG 需求参与企业文档检索方案的技术验证，重点进行 Embedding、Reranker 与本地推理方案的模型选型、对比和效果评测。
- 对多种模型配置进行离线实验，记录检索质量、推理延迟、内存占用与本地部署资源需求，并整理模型替换结果、优缺点及技术建议。
- 结合真实业务需求持续定位 Retrieval / Reranking Pipeline 的质量问题，迭代实验方案并形成可复用的评测记录；同步学习 Web 与 AI Server 相关工程技术，为后续系统开发与集成做准备。

项目经历

AI Knowledge Server / MAX｜个人 RAG 系统 2026 - 至今

Python · FastAPI · Vue 3 · ChromaDB · Cross-Encoder · Langfuse · APISIX · ONNX

- 搭建多语言 RAG 文档问答系统，支持 PDF、TXT、Markdown 文档解析与切分，通过本地 Embedding、ChromaDB 向量检索和 Cross-Encoder 重排生成带文件名及页码引用的可追溯回答。
- 接入 Langfuse，对 Query Rewrite、Vector Retrieval、Reranking、Answer Generation 进行全链路 Trace；定位本地模型冷启动瓶颈，并实现模型预热、检索候选去重、无依据拒答及 LLM 异常恢复。
- 建立 25 题验收集，对多种 Reranker 与 ONNX INT8 推理方案进行离线 Benchmark，综合评估 Evidence Recall@5、排序质量、延迟及内存占用；最佳离线实验取得 21/21 Evidence Recall@5。
- 完善可靠性与自动化测试机制，当前核心后端 183 项测试通过，前端测试及 Production Build 通过；Docker 配置已加入仓库并进行静态验证。

GitHub：github.com/maxwu2579/ai-knowledge-server

JARVIS | Agentic AI Personal Assistant 2026 - 至今

Python · FastAPI · React · TypeScript · SQLAlchemy · Alembic · Microsoft Graph

- 构建面向个人任务与知识管理的 Agent AI 助手，将自然语言请求转换为结构化任务提案，经程序校验与用户确认后再执行外部操作。
- 设计持久化任务执行引擎，支持任务队列、Human-in-the-loop 确认、Worker 重试、故障恢复、执行审计与幂等控制，避免重复执行。
- 接入 Microsoft Graph / Outlook Calendar，完成 OAuth 授权、加密凭据缓存与真实账户只读查询，并实现日历事件创建链路及离线故障测试；同时集成文档 RAG、引用校验与证据不足拒答。

GitHub：github.com/maxwu2579/jarvis-personal-assistant

AI 代码差异审查服务 2026

Python · FastAPI · asyncio · SSE · DeepSeek API · REST API · Cloudflare Tunnel

- 构建异步代码审查 HTTP 服务，接收 unified diff 后按文件边界分块扫描并生成结构化审查结果；客户端支持轮询与 SSE 获取结果，并通过 Cloudflare Tunnel 完成公网访问。
- 实现幂等键、内容缓存、滑动窗口限流与信号量并发控制；抽象统一 Provider 接口，使本地规则引擎与 DeepSeek 共用同一流水线，并在模型不可达时保持服务稳定降级。

GitHub：github.com/maxwu2579/diff-review-service

游戏自动化机器人 2024 - 2026

Python · PyAutoGUI · OpenCV · Tkinter

- 基于 OpenCV 模板匹配与 PyAutoGUI 开发桌面自动化工具，与游戏界面元素进行识别和交互，减少重复性操作，并在短暂商用后开源发布。
- 通过调整模板匹配阈值降低视觉相似界面下的误识别，并提供 Tkinter 控制面板、一键启停和多种自动化模式。

GitHub：github.com/maxwu2579/bot-server

技术技能

编程语言： Python · TypeScript · JavaScript · SQL · Java · C++

AI / LLM： RAG · Embedding · Vector Search · Reranking · Agent · Tool / Function Calling · Structured Output · Langfuse · ONNX

Web / 全栈： FastAPI · Flask · React · Vue 3 · Next.js · Node.js · REST API · SSE · asyncio

数据 / 工程： PostgreSQL · MySQL · SQLite · ChromaDB
SQLAlchemy · Alembic · Docker · APISIX · Git · GitHub · Microsoft Graph

证书 / 语言： AWS Cloud Practitioner（2024） · 中文（母语） · 英语（流利）